UTN.BA | Centro de e-Learning

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Diplomatura en Ciencia de Datos y Análisis Avanzado

Entrega trabajo final integrador:

Detección temprana de transacciones potencialmente ilícitas (Anti-Money Laundering, AML)

Integrantes:

- Sezaro, Tomás
- Islas, Cecilia
- Frias, Noelia
- Gottig, Nicolas

Fecha: 31/03/2026

Contenido

Resumen Ejecutivo **3**

Definición del Problema y Relevancia **4**

Datos y Metodología **5**

- **Fuente y características de los datos** 5
- **Análisis Exploratorio de Datos (EDA)** 6
- **Preparación de los datos** 7
- **Ingeniería de variables** 7
- **Metodología aplicada** 8
- **Conclusiones del EDA** 8

Modelado y Evaluación **9**

- **Algoritmos evaluados** 9
- **Métricas de evaluación** 9
- **Resultados obtenidos y Selección del modelo final** 10

Impacto en el Negocio **11**

- **Beneficios esperados** 11
- **Áreas involucradas y acciones** 11
- **Riesgos y limitaciones** 12
- **Escalabilidad y pasos futuros** 12

Conclusión General del Trabajo **12**

Bibliografía Consultada **13**

Resumen Ejecutivo

El presente trabajo tiene como objetivo desarrollar un modelo predictivo capaz de identificar eventos relevantes a partir del análisis de datos históricos, con el fin de mejorar la toma de decisiones y optimizar la asignación de recursos. Este tipo de solución resulta especialmente valiosa en contextos donde anticipar determinados comportamientos permite actuar de manera proactiva y generar impacto en el negocio.

Para abordar este desafío, se diseñó una solución basada en técnicas de Machine Learning, evaluando distintos algoritmos y seleccionando como modelo principal a LightGBM. Este modelo se destaca por su eficiencia computacional, su capacidad para capturar relaciones complejas en los datos y su escalabilidad en entornos de gran volumen de información.

Los resultados obtenidos evidencian una sólida capacidad del modelo para discriminar entre distintos tipos de eventos, logrando métricas destacadas como un ROC-AUC superior a 0.98, lo que indica un alto poder de separación entre clases. Asimismo, el modelo presenta una elevada sensibilidad (recall), superando el 85%, lo que demuestra su efectividad para detectar la mayoría de los casos de interés.

Desde una perspectiva de negocio, esta solución permite priorizar casos en función de su probabilidad estimada, facilitando la implementación de estrategias focalizadas, como revisiones manuales, intervenciones tempranas o asignación eficiente de recursos. De esta manera, el modelo se convierte en una herramienta clave para mejorar la eficiencia operativa y reducir riesgos asociados a la no detección de eventos relevantes.

Si bien el desempeño general del modelo es altamente satisfactorio, se observa que existe un desafío adicional en términos de precisión sobre la clase de interés, lo cual es un aspecto común en este tipo de problemas y representa una oportunidad de mejora futura mediante la incorporación de nuevas variables o enfoques complementarios.

En conclusión, el modelo desarrollado constituye una base sólida para la implementación de soluciones analíticas en el negocio, destacándose por su capacidad predictiva y su potencial para escalar hacia aplicaciones más avanzadas.

Definición del Problema y Relevancia

En muchos contextos de negocio, resulta fundamental poder identificar de manera anticipada ciertos eventos relevantes que, aunque poco frecuentes, pueden tener un impacto significativo en la operación o en la toma de decisiones. La detección temprana de estos casos permite a las organizaciones actuar de forma proactiva, optimizando recursos y reduciendo riesgos asociados.

En este trabajo, el problema a resolver consiste en desarrollar un modelo predictivo capaz de clasificar correctamente estos eventos a partir de información histórica disponible. Específicamente, se busca determinar la probabilidad de que un registro pertenezca a la clase de interés, permitiendo diferenciarlo del comportamiento general del resto de los datos.

El objetivo del proyecto es construir un modelo de Machine Learning que permita maximizar la capacidad de detección de estos eventos, utilizando métricas adecuadas para evaluar su desempeño. En particular, se prioriza alcanzar un alto nivel de recall (superior al 85%), asegurando que la mayor cantidad posible de casos relevantes sean identificados. Complementariamente, se consideran métricas como ROC-AUC y F1-score para evaluar la capacidad global del modelo y su equilibrio entre precisión y sensibilidad.

Desde el punto de vista estratégico, la implementación de este tipo de modelo habilita la articulación entre distintas áreas del negocio, transformando el análisis de datos en acciones concretas. Por ejemplo, equipos de riesgo o control pueden utilizar el output del modelo para priorizar revisiones manuales, mientras que áreas operativas pueden ajustar procesos en función de alertas tempranas. Asimismo, áreas comerciales o de experiencia de cliente podrían activar estrategias específicas sobre los casos detectados, como intervenciones proactivas, seguimiento personalizado o ajustes en la comunicación.

Adicionalmente, el modelo permite evolucionar hacia un enfoque basado en priorización y gestión por score, donde distintas áreas trabajan de manera coordinada sobre un mismo insumo analítico. Esto abre la puerta a la implementación de flujos automatizados, asignación inteligente de recursos y definición de umbrales de acción según el nivel de riesgo o probabilidad estimada. En este sentido, la solución no solo aporta valor desde lo predictivo, sino que también se posiciona como un habilitador clave para la toma de decisiones basada en datos y la optimización integral de procesos dentro de la organización.

Datos y Metodología

Fuente y características de los datos

Para el desarrollo del presente trabajo se utilizó el dataset IBM Transactions for Anti Money Laundering (AML), generado mediante el simulador AMLSim, el cual replica el comportamiento de un sistema bancario real. Este dataset contiene millones de transacciones financieras entre cuentas, incluyendo distintos formatos de pago (transferencias ACH, wire, criptomonedas, entre otros), múltiples monedas y registros temporales detallados.

El conjunto de datos está compuesto por dos archivos principales en formato CSV:

- HI-Small_Trans.csv: contiene información a nivel transaccional, donde cada registro representa una operación financiera individual.
- HI-Small_accounts.csv: incluye información estructural de las cuentas, permitiendo enriquecer el análisis mediante variables contextuales.

En términos de volumen, el dataset presenta más de 5 millones de transacciones y más de 500 mil cuentas, lo que lo posiciona como un escenario representativo de entornos reales de alta escala. La variable objetivo es Is Laundering, una variable binaria que indica si la transacción está asociada a un posible evento de lavado de dinero.

Se identifica un marcado desequilibrio en la distribución de la variable objetivo. Esta condición es intrínseca a los escenarios de detección de lavado de dinero (AML), donde la prevalencia de transacciones ilícitas es mínima en comparación con el volumen total de operaciones legítimas, lo que exige técnicas específicas de tratamiento de datos.

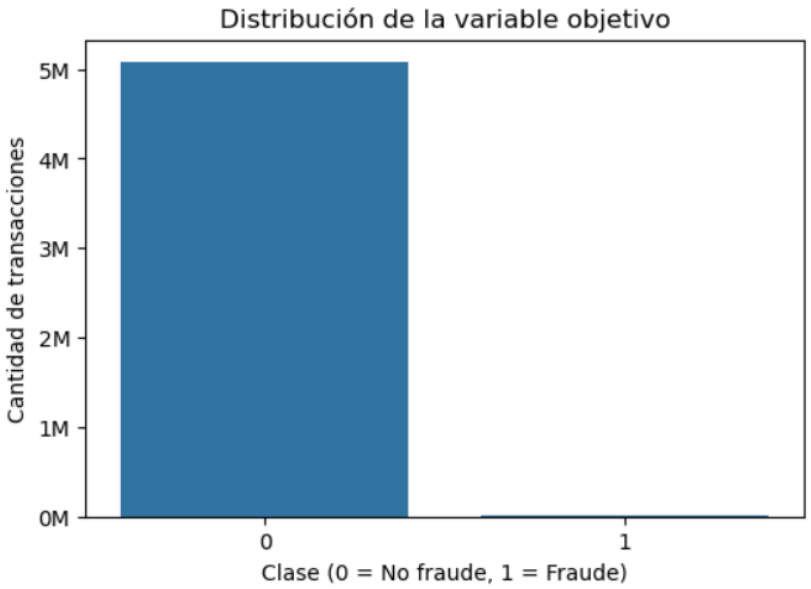

Análisis Exploratorio de Datos (EDA)

Se realizó un análisis exploratorio con el objetivo de comprender la estructura del dataset, identificar patrones relevantes y evaluar la calidad de los datos.

Durante esta etapa se analizaron:

- Distribución de montos transaccionales
- Frecuencia de transacciones por tipo de pago
- Comportamiento temporal de las operaciones
- Diferencias entre transacciones legítimas y potencialmente ilícitas

El análisis permitió identificar que ciertas variables, como el monto de la transacción, el tipo de pago y el comportamiento temporal, presentan patrones diferenciados que pueden ser aprovechados por modelos predictivos.

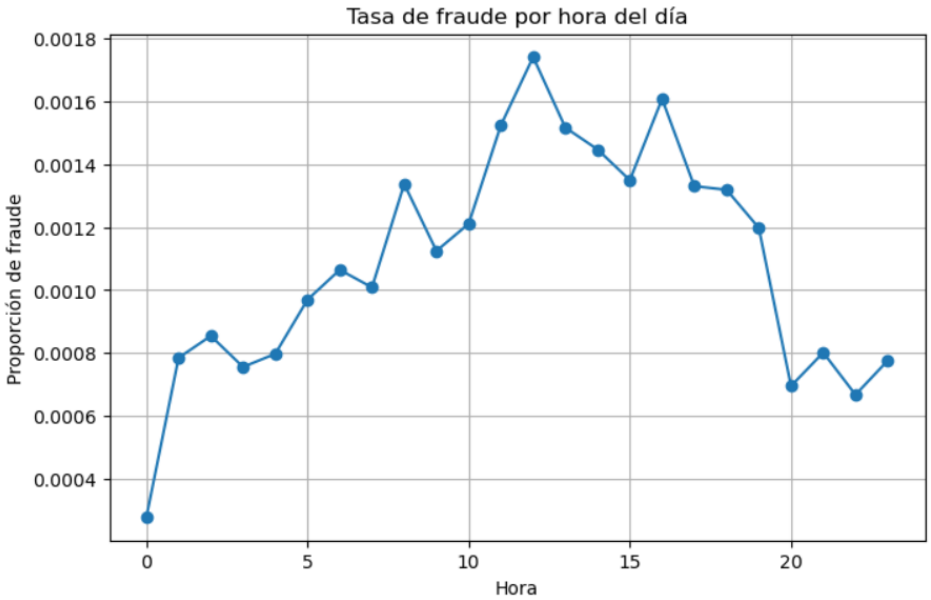

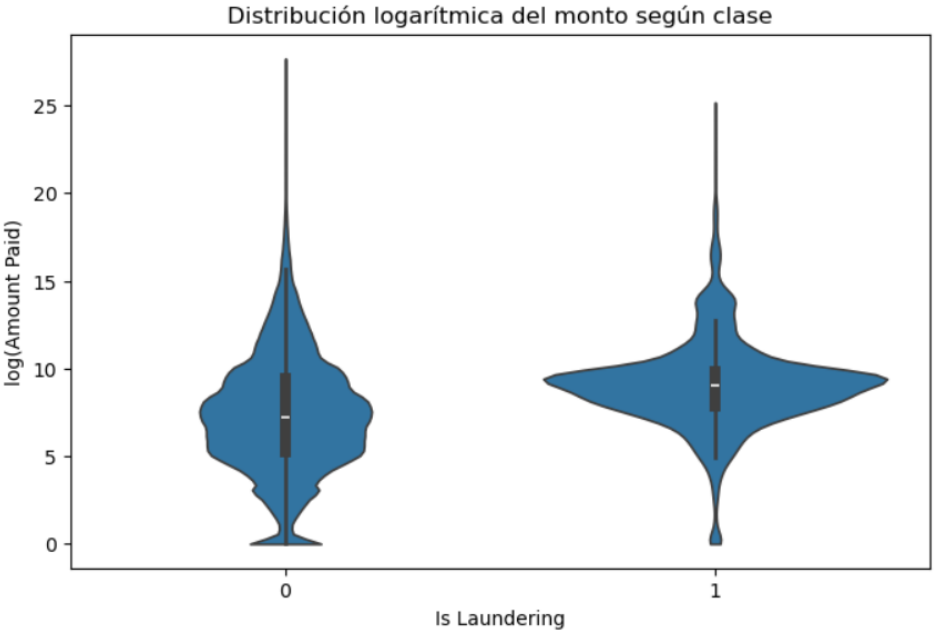

Preparación de los datos

Con el objetivo de garantizar la calidad del dataset, se realizaron diversas tareas de limpieza y transformación.

En primer lugar, la variable **Timestamp** fue convertida a formato datetime, permitiendo su utilización en análisis temporal. Posteriormente, se verificó la existencia de valores faltantes, registros duplicados y posibles inconsistencias en los montos, asegurando la coherencia de la información.

Dado el volumen de datos, también se aplicaron optimizaciones orientadas a la eficiencia computacional. Se transformaron variables categóricas como *Payment Format*, *Currency* y *Bank IDs* a tipo category, y la variable objetivo a un tipo numérico reducido (int8). Asimismo, se monitoreó el uso de memoria mediante memory_usage="deep", logrando una reducción significativa en el consumo de recursos.

Finalmente, las variables categóricas fueron codificadas adecuadamente para su utilización en modelos de Machine Learning, garantizando estabilidad en el proceso de entrenamiento.

Ingeniería de variables

Con el objetivo de mejorar la capacidad predictiva del modelo, se generaron variables derivadas que capturan patrones de comportamiento transaccional relevantes.

Entre las principales transformaciones se incluyen:

- **Componentes temporales**: hora del día y día de la semana de la transacción.
- **Transformación logarítmica del monto**: para reducir la asimetría en la distribución de valores.
- **Indicador de transacciones interbancarias**: identifica operaciones entre distintas entidades.
- **Indicador de auto-transferencias**: detecta operaciones entre la misma cuenta.
- **Codificación del formato de pago**: preservando información sobre el canal utilizado.
- **Actividad histórica por cuenta**: número acumulado de transacciones previas.

Estas variables permiten capturar comportamientos más complejos y enriquecen significativamente la información disponible para el modelo.

Metodología aplicada

El desarrollo del proyecto se estructuró siguiendo la metodología **CRISP-DM**, que organiza el proceso de análisis en etapas iterativas:

1. **Comprensión del negocio**: definición del problema y objetivos.
2. **Comprensión de los datos**: análisis exploratorio y evaluación de calidad.
3. **Preparación de los datos**: limpieza, transformación e ingeniería de variables.
4. **Modelado**: entrenamiento de distintos algoritmos, destacándose **LightGBM**.
5. **Evaluación**: análisis de métricas como ROC-AUC, Recall y F1-score.
6. **Aplicación conceptual**: interpretación de resultados y potencial uso en el negocio.

Conclusiones del EDA

El análisis exploratorio permitió comprender la estructura y comportamiento del dataset, identificando patrones relevantes en la variable objetivo (Is Laundering) y su relación con distintas variables.

En primer lugar, se observa que las transacciones asociadas a lavado de dinero representan una proporción muy reducida del total, lo cual es consistente con escenarios reales y plantea un desafío para el modelado.

Desde el punto de vista monetario, los montos presentan una distribución altamente asimétrica. El análisis por rangos muestra que la tasa de fraude tiende a concentrarse en niveles intermedios-altos, más que en los valores extremos.

En la dimensión temporal, se identifican variaciones en la tasa de fraude según el momento del día, así como posibles cambios en el comportamiento a lo largo del tiempo, lo que sugiere que estas variables pueden aportar valor predictivo.

Por otro lado, variables categóricas como el tipo de pago y el tipo de entidad muestran diferencias en la incidencia del fraude, destacándose algunos métodos con mayor proporción relativa de casos.

En conjunto, el EDA evidencia que el fraude surge de la combinación de múltiples factores y no de una única variable aislada. Estos hallazgos orientan la construcción del modelo, destacando la importancia de incorporar variables derivadas y considerar la complejidad del problema.

Modelado y Evaluación

Algoritmos evaluados

Con el objetivo de construir un modelo capaz de identificar transacciones asociadas a lavado de dinero, se evaluaron distintos algoritmos de clasificación supervisada sobre el dataset preparado.

Entre los modelos analizados se incluyen:

- **Regresión Logística**, como modelo base interpretable.
- **Random Forest**, para capturar relaciones no lineales mediante ensamble de árboles.
- **LightGBM**, como modelo de boosting optimizado para grandes volúmenes de datos.

La selección de estos modelos responde a la necesidad de comparar enfoques simples e interpretables con modelos más complejos y performantes, especialmente en contextos de datos estructurados y de gran escala.

Métricas de evaluación

Dado el tipo de problema, se priorizaron métricas que permiten evaluar correctamente el desempeño sobre la clase de interés. En particular, se consideraron:

- **Recall**: para medir la capacidad de detectar transacciones fraudulentas.
- **Precision**: para evaluar la proporción de aciertos entre las predicciones positivas.
- **F1-score**: como balance entre precision y recall.
- **ROC-AUC**: para medir la capacidad global de discriminación del modelo.
- **PR-AUC**: especialmente relevante en contextos con baja proporción de la clase positiva.

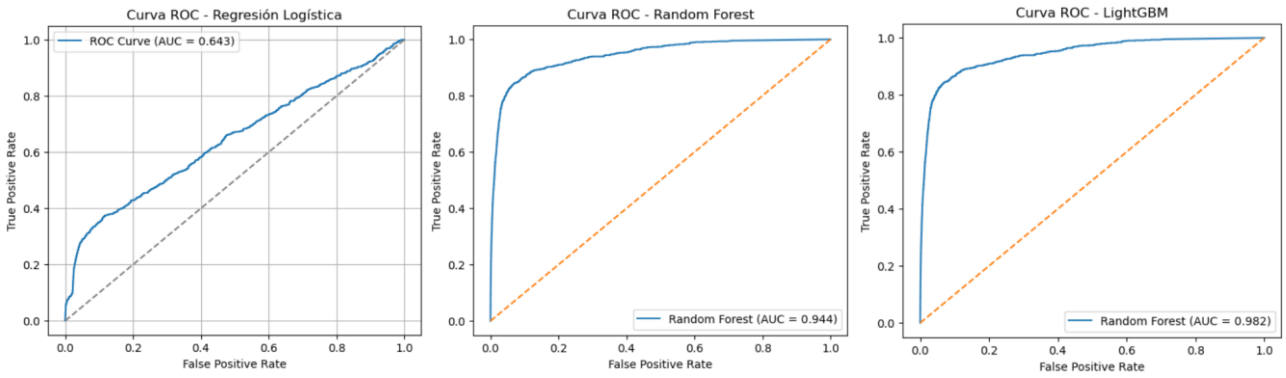

Resultados obtenidos y Selección del modelo final

En base a los resultados obtenidos, se seleccionó **LightGBM** como modelo final.
La elección se fundamenta en:

- Su **alta capacidad de detección de la clase de interés (recall elevado)**
- Su **excelente desempeño en métricas globales (ROC-AUC)**
- Su capacidad para modelar relaciones complejas en grandes volúmenes de datos

Si bien la precision presenta margen de mejora, el modelo resulta adecuado para escenarios donde es prioritario no omitir casos relevantes, permitiendo su uso como herramienta de priorización y soporte a la toma de decisiones.

En particular, el modelo **LightGBM** se destaca por su alta capacidad de discriminación, alcanzando valores de **ROC-AUC superiores a 0.98**, lo que indica una excelente separación entre clases.
Asimismo, el modelo logra un **alto recall (mayor al 85%)**, lo que significa que es capaz de identificar la mayoría de las transacciones fraudulentas. Sin embargo, la **precision se mantiene baja**, reflejando una alta cantidad de falsos positivos, lo cual impacta directamente en el F1-score.
Durante el proceso de optimización, se aplicaron distintas estrategias para mejorar el desempeño:

- Ajuste del **threshold de decisión**
- Reponderación de clases mediante **scale_pos_weight**
- Técnicas de balanceo como **SMOTE**

Si bien estas técnicas permitieron analizar el comportamiento del modelo bajo distintos escenarios, no se observaron mejoras significativas en la precision, lo que sugiere que la limitación principal radica en la capacidad de separación de las variables disponibles.

Impacto en el Negocio

La implementación de un modelo predictivo para la detección de transacciones asociadas a lavado de dinero permite transformar grandes volúmenes de datos en acciones concretas, mejorando la capacidad de respuesta del negocio frente a eventos críticos.

Beneficios esperados

Con la aplicación del modelo se busca:

- Detectar de manera temprana transacciones con alta probabilidad de estar asociadas a actividades ilícitas.
- Priorizar la revisión de operaciones por parte de equipos de riesgo y compliance.
- Reducir la exposición a riesgos regulatorios y financieros derivados de la no detección de operaciones sospechosas.
- Automatizar procesos de monitoreo, disminuyendo la dependencia de análisis manuales sobre grandes volúmenes de datos.
- Mejorar la eficiencia operativa al enfocar esfuerzos en los casos más relevantes según el score del modelo.
- Generar un sistema de alertas tempranas que permita actuar de forma preventiva sobre comportamientos sospechosos.

Áreas involucradas y acciones

La implementación de este tipo de solución habilita la coordinación entre distintas áreas:

Área	Acción	Beneficio
Riesgo / Compliance	Revisión priorizada de transacciones sospechosas	Mejora en detección de fraude
Operaciones	Ajuste de procesos según alertas del modelo	Mayor eficiencia operativa
Tecnología / Data	Integración del modelo en sistemas productivos	Automatización y escalabilidad
Auditoría	Monitoreo de patrones y validación de decisiones	Mayor control y trazabilidad

Área	Acción	Beneficio
Atención al cliente	Gestión de casos detectados	Reducción de impacto en clientes

Riesgos y limitaciones

A pesar de los beneficios, existen ciertos desafíos a considerar:

- **Falsos positivos**: el modelo puede identificar como sospechosas transacciones legítimas, generando sobrecarga operativa.
- **Dependencia de la calidad de datos**: inconsistencias o falta de información pueden afectar el desempeño del modelo.
- **Limitaciones en la capacidad predictiva**: la superposición entre clases puede dificultar la mejora de la precisión.
- **Necesidad de monitoreo continuo**: los modelos deben actualizarse para adaptarse a cambios en los patrones de comportamiento.

Escalabilidad y pasos futuros

El modelo desarrollado sienta las bases para una solución escalable dentro de la organización. Entre las posibles evoluciones se destacan:

- Integración en sistemas productivos para scoring en tiempo real.
- Incorporación de nuevas variables y fuentes de datos para mejorar la capacidad predictiva.
- Desarrollo de modelos complementarios (por ejemplo, detección de anomalías).
- Automatización de flujos de decisión basados en niveles de riesgo.
- Extensión del modelo a otros casos de uso relacionados, como detección de fraude en distintos productos o segmentos.

Conclusión General del Trabajo

El presente trabajo abordó el problema de detección de transacciones asociadas a lavado de dinero utilizando un dataset transaccional de gran escala. Se evaluaron distintos enfoques de clasificación supervisada, incluyendo Regresión Logística, Random Forest y LightGBM, con el objetivo de comparar su desempeño en la identificación de la clase de interés.

Los resultados muestran que, a medida que aumenta la complejidad del modelo, mejora la capacidad para capturar patrones no lineales presentes en los datos. En este sentido, la Regresión Logística funcionó como un baseline interpretable, mientras que Random Forest permitió una mejor representación de relaciones complejas.
Por su parte, LightGBM se posiciona como el modelo con mejor desempeño general, destacándose por su alta capacidad de discriminación y su eficiencia en el manejo de grandes volúmenes de datos. Su enfoque basado en boosting le permite focalizarse en los casos más difíciles, lo que resulta especialmente valioso en este tipo de problemas.
No obstante, se observa que el principal desafío continúa siendo la correcta identificación de la clase minoritaria, lo cual impacta en métricas como la precisión. Este comportamiento es consistente con la naturaleza del problema y abre oportunidades de mejora futura mediante la incorporación de nuevas variables y enfoques complementarios.
En conclusión, el trabajo demuestra que los modelos basados en boosting, particularmente LightGBM, representan una alternativa sólida y escalable para este tipo de problemáticas, permitiendo sentar las bases para futuras implementaciones en entornos reales.

Bibliografía Consultada

- IBM. AMLSim: Synthetic Data Generator for Anti-Money Laundering Research. Disponible en: https://github.com/IBM/AMLSim
- Kaggle. IBM AML Transactions Dataset. Disponible en: https://www.kaggle.com/
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems (NeurIPS).
- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.
- Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques. Morgan Kaufmann.
- Documentación oficial de Python: https://docs.python.org/
- Documentación de Pandas: https://pandas.pydata.org/docs/
- Documentación de Scikit-learn: https://scikit-learn.org/stable/
- Documentación de LightGBM: https://lightgbm.readthedocs.io/